

MOT, LANGAGES ET EXPRESSIONS RÉGULIÈRES

PLAN

1. Introduction
2. Terminologie
3. Opérations sur les mots
4. Opérations sur les langages
5. Langages formels
6. Expressions régulières
7. Langages réguliers

INTRODUCTION

- La théorie des langues est issue de la linguistique, comme moyen de formaliser les langues naturelles.
- En informatique, les langages formels sont souvent utilisés comme base pour la définition des langages de programmation.
- Un compilateur est un utilitaire de traduction permettant, à partir d'un programme écrit dans un langage de "haut niveau" (par exemple C++), de vérifier la syntaxe du programme de départ, puis de produire un fichier en un langage de niveau plus bas, exécutable par le système d'exploitation.

INTRODUCTION

Les tâches préliminaires d'un compilateur sont :

- **analyse lexicale**: segmenter le programme, vu comme une suite de caractères, en des unités cohérentes et de catégoriser ces unités (mot-clé, variable, constante, etc)
- **analyse syntaxique**: vérifier la conformité avec les règles de constitution du code. Par exemple, l'expression $(x+y)) = z$ est syntaxiquement incorrecte.
- **analyse sémantique**: analyser le sens et mettre en évidence la structure interne du programme. Par exemple, un compilateur d'expression arithmétique doit pouvoir analyser la séquence $x+y*z$ comme $x+(y*z)$

TERMINOLOGIE

Alphabet (ou vocabulaire):

Ensemble fini de symboles, noté en général par Σ .

- Alphabet Latin $\Sigma=\{a,b,c,\dots,z\}$
- Alphabet binaire $\Sigma=\{0,1\}$
- $\Sigma=\{\text{point},\text{ligne},0,1,x\}$

TERMINOLOGIE

Mot (ou chaîne):

Suite finie (éventuellement vide) d'éléments de Σ noté w .
Par convention, le mot vide est noté ε .

- $u = \text{clavier}$; $v = \text{souris}$ deux mots définies sur l'alphabet Latin
- $u = 00110$; $v = 010010$ sont deux mots définis sur l'alphabet binaire.
- $u = \text{point} \mid \text{ligne}$; $v = 10xx\text{ligne}$: sont deux mots définis sur l'alphabet $\Sigma = \{\text{point}, \text{ligne}, 0, 1, x\}$

TERMINOLOGIE

Longueur (ou taille) d'un mot :

$|w|$ = nombre de symboles constituant le mot.

- $|\text{point}|=5$ en considérant l'alphabet Latin
- $|101|=3$ en considérant l'alphabet binaire
- $|\text{point}|=1$ en considérant l'alphabet $\Sigma=\{\text{point},\text{ligne},0,1,x\}$
- $|\varepsilon|=0$

TERMINOLOGIE

Fermeture

Soit Σ , un alphabet. On note par Σ^* , l'ensemble de toutes les séquences finies de symboles de Σ .

Le symbole $*$ est une fonction qui, appliquée à un ensemble non vide Σ , donne un autre ensemble infini Σ^* .

On dit que Σ^* est la fermeture de Σ .

Exemple:

$\Sigma=\{a,b\} \Rightarrow \Sigma^* = \{\epsilon, a, b, ab, ba, aa, bb, aab, abb, aaa, \dots\}$

TERMINOLOGIE

Fermeture

L'ensemble de tous les mots non-vides formés à partir de Σ est noté Σ^+ .

On note par Σ^k l'ensemble des mots sur Σ de longueur k

Exemple : $\Sigma = \{a,b\}$

- $\Sigma^1 = \{a,b\}$
- $\Sigma^2 = \{aa,ab,ba,bb\}$
- $\Sigma^0 = \{\varepsilon\}$

TERMINOLOGIE

Fermeture

On a donc :

$$\Sigma^* = \{\epsilon\} \cup \Sigma^+$$

$$\Sigma^+ = \Sigma^1 \cup \Sigma^2 \cup \Sigma^3 \cup \dots$$

$$\Sigma^* = \Sigma^0 \cup \Sigma^1 \cup \Sigma^2 \cup \dots$$

TERMINOLOGIE

Langage

Ensemble de mots sur un alphabet.

Un langage sur Σ est un sous-ensemble de Σ^* .

Un langage L est un ensemble de mots appartenant à Σ^* et qui vérifie une propriété donnée :

$$L = \{w \in \Sigma^* \mid w \text{ possède la propriété } P\}$$

TERMINOLOGIE

Langage

Exemples:

- Ensemble des mots anglais légaux
- Ensemble de programmes C corrects syntaxiquement
- Ensemble des mots de l'alphabet binaire contenant un nombre n de 0 suivi par le même nombre n de 1.

$$L = \{\epsilon, 01, 0011, 000111, \dots\}.$$

TERMINOLOGIE

Langage

- Le langage vide $L = \emptyset$
- Le langage $\{\epsilon\}$ contenant le mot vide.
- $\emptyset \neq \{\epsilon\}$

TERMINOLOGIE

Exercice:

$$\Sigma = \{a, b\}$$

- Ensemble des mots ayant le même nombre des a et des b.
- Ensemble des mots de longueur strictement inférieure à 2
- $\{aa, aaa, aaaaa, aaaaaaa, \dots\}$
- $\{ab, aab, abb, aaab, abbb, aabb, abab, \dots\}$
- $\{a, b, aba, bab, aabaa, bbabb, \dots\}$

TERMINOLOGIE

Correction :

$$\Sigma = \{a, b\}$$

- Ensemble des mots ayant le même nombre des a et des b.

$$L_1 = \{ \epsilon, ab, ba, aabb, baba, \dots \}$$

- Ensemble des mots de longueur strictement inférieure à 2

$$L_2 = \{ \epsilon, a, b \}$$

TERMINOLOGIE

- $\{aa, aaa, aaaaa, aaaaaaa, \dots\}$

Ensemble des mots composés d'un nombre *premier* de a

- $\{ab, aab, abb, aaab, abbb, aabb, abab, \dots\}$

Ensemble des mots qui commencent par a et finissent par b

- $\{a, b, aba, bab, aabaa, bbabb, \dots\}$

Ensemble des mots palindromes

OPÉRATIONS SUR LES MOTS

Concaténation

- L'opération de concaténation de deux mots u et v de Σ^* résulte en un nouveau mot uv , constitué par la juxtaposition des symboles de u et des symboles de v .
- Soient u, v deux mots définis sur Σ , tq $u = x_1 x_2 \dots x_n$, $v = y_1 y_2 \dots y_n$
La chaîne ω concaténation de u et v est $\omega = u.v = uv = x_1 \dots x_n y_1 \dots y_n$
- On a alors $|uv| = |u| + |v|$

OPÉRATIONS SUR LES MOTS

Concaténation

- La concaténation est une opération interne de Σ^*
- Elle est associative, mais pas commutative

$$uvt = (uv)t = u(vt)$$

- ε est l'élément neutre pour la concaténation

$$u.\varepsilon = \varepsilon.u = u$$

OPÉRATIONS SUR LES MOTS

Concaténation

- On note u^n la concaténation de n copies de u . Par exemple:
 - $u^0 = \varepsilon$.
 - $u^3 = uuu$
 - $u^k = uuuu\dots$ (k fois)
- Un mot non-vide v est **primitif** si l'équation $v = u^i$ n'admet pas de solution pour $i > 1$. Par exemple, le mot $abab$ n'est pas primitif, parce qu'il est le carré du mot ab .

OPÉRATIONS SUR LES MOTS

Concaténation

$$u^* = \{u^i / i \geq 0\} = \{u^0, u^1, u^2, \dots, u^i, \dots\}$$

$$u^+ = \{u^i / i > 0\} = \{u^1, u^2, u^3, \dots, u^i, \dots\}$$

OPÉRATIONS SUR LES MOTS

Occurrence d'un symbole dans un mot :

$|w|_x$ est le nombre total d'occurrences du symbole x dans le mot w .

On a donc : $|w| = \sum_{x \in \Sigma} |w|_x$

Exercice:

Quel est le nombre d'occurrences de y dans les mots ε et $xyybc$

- $|xyybc|_y = 2$
- $|\varepsilon|_y = 0$

OPÉRATIONS SUR LES MOTS

Préfixes et suffixes

- Les **préfixes** d'un mot $u = x_1x_2..x_n$ sont les $n+1$ mots ε et $x_1...x_i$ pour $i=1,...,n$.
- Les **suffixes** d'un mot $u = x_1x_2..x_n$ sont les $n+1$ mots ε et $x_i...x_n$ pour $i=1,...,n$.
- Si on exclut le mot vide, on parle de préfixe (resp. suffixe) *non vide*.
- Si on exclut le mot lui-même, on parle de préfixe (resp. suffixe) *propre*.
- On note $|pref|_k(u)$ (resp. $|suff|_k(u)$) le préfixe (resp. le suffixe) de longueur k de u .

OPÉRATIONS SUR LES MOTS

Préfixes et suffixes

Exercice:

Quels sont les préfixes et les suffixes du mot $xyxz$?

Correction:

- les préfixes du mot $xyxz$ sont : $\varepsilon, x, xy, xyx, xxyz$
- les suffixes du mot $xyxz$ sont : $\varepsilon, z, xz, yxz, xxyz$

De manière équivalente :

- u est un préfixe de ω ssi $\exists v$ tq $\omega = uv$
- v est un suffixe de ω ssi $\exists u$ tq $\omega = uv$

OPÉRATIONS SUR LES MOTS

Facteurs et sous-mots

- On dit que u est un **facteur** de v s'il existe u_1 et u_2 dans Σ^* tels que $v = u_1 u u_2$.
- Si $u_2 = \varepsilon$ alors u_1 est dit facteur gauche de v (ou préfixe)
- Si $u_1 = \varepsilon$ alors u_2 est dit facteur droite de v (ou suffixe)
- Si $u_1 = u_2 = \varepsilon$ alors v est un facteur de lui même
- On appelle facteur propre de v tout facteur de v différent de v .

OPÉRATIONS SUR LES MOTS

Facteurs et sous-mots

- Si w se factorise en $u_1 v_1 u_2 v_2 \dots u_n v_n u_{n+1}$, où tous les u_i et v_i sont des mots de Σ^* , alors $v = v_1 v_2 \dots v_n$ est un sous-mot de w . Par exemple, 11 est sous-mot de 10100 (mais pas un facteur)
- Les sous-mots sont donc construits à partir de fragments non nécessairement contigus, mais dans lesquels l'ordre d'apparition des symboles est toutefois respecté.
- Tous les facteurs sont des sous-mots

OPÉRATIONS SUR LES MOTS

Image miroir

- L'image miroir ou transposé ω^R du mot $\omega = x_1 \dots x_n$, où $x_i \in \Sigma$, est défini par: $\omega^R = x_n \dots x_1$.

$$\omega = 001011 \longrightarrow \omega^R = 110100$$

- Un mot est un palindrome s'il est égal à son miroir. Par exemple, "ici" et "radar" sont des palindromes du vocabulaire commun.

$$L = \{ \omega \in \Sigma^*, \omega = \omega^R \}$$

OPÉRATIONS SUR LES LANGAGES

Opérations ensemblistes

- Union : $L_1 \cup L_2 = \{u \in \Sigma^* \mid u \in L_1 \text{ ou } u \in L_2\}$
- Intersection : $L_1 \cap L_2 = \{u \in \Sigma^* \mid u \in L_1 \text{ et } u \in L_2\}$
- Complémentation : $\bar{L} = \{u \in \Sigma^* \mid u \notin L\}$
- Les opérations $\cup$ et $\cap$ sont associatives et commutatives.

OPÉRATIONS SUR LES LANGAGES

Concaténation

- L'opération de concaténation, définie sur les mots, engendre naturellement la *concaténation de langages* :

$$L_1.L_2 = L_1L_2 = \{u \in \Sigma^* \mid \exists (x,y) \in L_1 \times L_2 \text{ tq } u=xy\}$$

- Cette opération est associative, mais pas commutative.
- L'itération de n copies du langage L se notera L^n .
- Par convention : $L^0 = \{\epsilon\}$.

OPÉRATIONS SUR LES LANGAGES

Propriétés

Soient L_1, L_2, L_3 des langages on a :

- $L_1.(L_2 \cup L_3) = L_1.L_2 \cup L_1.L_3$
- $(L_1 \cup L_2).L_3 = L_1.L_3 \cup L_2.L_3$
- $L_1 \subseteq L_2 \Rightarrow L_1 L_3 \subseteq L_2 L_3$
 $L_3 L_1 \subseteq L_3 L_2$

OPÉRATIONS SUR LES LANGAGES

Fermeture de Kleene

$$L^* = \{\omega \in \Sigma^* \mid \omega = \omega_1 \omega_2 \dots \omega_k \text{ pour } k \geq 0 \text{ et } \omega_1, \omega_2, \dots, \omega_k \in L\}$$

L'opération de fermeture (ou plus simplement l'étoile) de Kleene d'un langage L se définit par :

$$L^* = \bigcup_{i \geq 0} L^i$$

C'est à dire, si L est un langage alors L^* contient tous les mots formés par concaténation d'un nombre fini d'éléments du langage L , où chaque mot peut être utilisé de 0 à n fois, et le mot vide est aussi inclus.

OPÉRATIONS SUR LES LANGAGES

Fermeture de Kleene

Exemple

$$L = \{aa, b\}$$

$$L^* = \{\epsilon, b, aa, bb, aab, baa, bbb, aaaa, aabb, baab, bbaa, bbbb, aaaab, aabaa, aabbb, baaaa, bbaab, bbbba, bbbbb, \dots\}$$

Remarque:

$$\emptyset^* = \{\epsilon\} \neq \emptyset$$

$\emptyset^*$ est la répétition de 0 ou plusieurs fois de $\emptyset$

OPÉRATIONS SUR LES LANGAGES

Fermeture de Kleene

On définit également :

$$L^+ = \bigcup_{i \geq 1} L^i$$

L^* contient toujours ε alors que L^+ ne contient ε que si L le contient. On a :

- $L^+ = LL^* = L^*L$
- $L^* = L^+ \cup \{\varepsilon\}$

OPÉRATIONS SUR LES LANGAGES

Exercice:

soit $\Sigma = \{0, 1\}$

$L = \{\omega \in \Sigma^* \mid \omega \text{ contient } |w|_0 \neq |w|_1\}$

Montrer que $L^* = \Sigma^*$

$L = \{1, 0, 101, 110, \dots\}$

OPÉRATIONS SUR LES LANGAGES

Correction:

$$L^* \subseteq \Sigma^* \text{ (par définition)} \quad (1)$$

$$\text{On a } \Sigma \subseteq L \Rightarrow \Sigma^* \subseteq L^* \quad (2)$$

$$(1) \text{ et } (2) \Rightarrow L^* = \Sigma^*$$

LANGAGES FORMELS

Un langage formel est tout sous ensemble de Σ^* dont les mots peuvent être définis de deux façons :

- Définition **par propriété**
- Définition **récursive**

LANGAGES FORMELS

Définition par propriété

Il s'agit d'une modélisation formelle d'une description naturelle d'un langage.

Exemple

$$\Sigma = \{a,b\}$$

$$L_1 = \{\text{ensemble des mots définis sur } \Sigma \text{ de longueur paire}\}$$

$$L_1 = \{\omega \in \Sigma^* / |\omega| = 2k \text{ avec } k \geq 0\}$$

LANGAGES FORMELS

Définition récursive

Définition dans laquelle, un langage est défini sur lui-même.

Exemple:

$$\Sigma = \{a,b\}$$

$$L_2 = \{\omega \in \Sigma^* / \omega = \varepsilon \text{ ou } \omega = uv \text{ avec } |u| = 2 \text{ et } v \in L_2\}$$

$$L_2 = L_1$$

LANGAGES FORMELS

Exercice:

$$\Sigma = \{a, b\}$$

Donner la définition par propriété et la définition récursive des langages suivants:

1. L_1 est l'ensemble des mots sur Σ où tous les a précèdent les b et sont de même nombre
2. L_2 est l'ensemble des mots palindromes sur Σ

LANGAGES FORMELS

Correction:

L_1 est l'ensemble des mots sur Σ où tous les a précèdent les b et sont de même nombre

- Définition par propriété

$$L_1 = \{ \omega \in \{a,b\}^* / \omega = a^n b^n, n \geq 0 \}$$

- Définition récursive

$$L_1 = \{ \omega \in \{a,b\}^* / \omega = \varepsilon \text{ ou } \omega = a\omega_1 b \text{ et } \omega_1 \in L_1 \}$$

LANGAGES FORMELS

Correction:

L_2 est l'ensemble des mots palindromes sur Σ

- Définition par propriété

$$L_2 = \{\omega \in \{a,b\}^* / \omega = \omega^R\}$$

- Définition récursive

$$L_2 = \{\omega \in \{a,b\}^* / \omega = \varepsilon, \omega = a \text{ ou } \omega = b \text{ ou } \omega = a\omega_1 a \text{ ou } \omega = b\omega_1 b \text{ et } \omega_1 \in L_2\}$$

EXPRESSIONS RÉGULIÈRES

Exemples Introductifs

- $L_1 = \{\text{tous les mots (éventuellement vide) formés par un nombre quelconque de } a\}$
= $\{\epsilon, a, aa, aaa, aaaa, aaaaa, \dots\}$
= langage (a^*)
- $L_2 = \{\text{tous les mots qui commencent par un } a \text{ suivi par un nombre quelconque de } b \}$
= $\{a, ab, abb, abbb, abbbb, \dots\}$
= langage (ab^*)

EXPRESSIONS RÉGULIÈRES

Exemples Introductifs

- $L_3 = \{\text{tous les mots de a et de b qui ont au moins 2 lettres, qui commencent et finissent par a et qui n'ont que des b ou rien à l'intérieur}\}$
= $\{aa, aba, abba, abbba, abbbbba, \dots\}$
= langage (ab^*a)
- $L_4 = \{\text{tous les mots de a et de b dans lesquelles tous les a viennent avant tous les b}\}$
= $\{\epsilon, a, b, aa, ab, bb, aaa, aab, abb, bbb, \dots\}$
= langage (a^*b^*)

Il est à noter que : $a^*b^* \neq (ab)^*$

EXPRESSIONS RÉGULIÈRES

Exemples Introductifs

- $L_5 = \{\text{tous les mots sur } \Sigma = \{a, b, c\} \text{ qui commencent avec un } a \text{ ou un } c \text{ suivi par un nombre quelconque de } b\}$
= langage $((a \cup c) b^*)$
- $L_6 = \{\text{tous les mots de } a \text{ et de } b \text{ de longueur } 3 \text{ exactement}\}$
= langage $((a \cup b) (a \cup b) (a \cup b))$
- $L_7 = \{\text{tous les mots de } a \text{ et de } b \text{ dans lesquels apparaît au moins une fois le facteur } aaa\}$
= langage $((a \cup b)^*aaa(a \cup b)^*)$

EXPRESSIONS RÉGULIÈRES

Définition

Une expression régulière sur un alphabet Σ est un mot sur l'alphabet $\Sigma \cup \{(), \cup, *, \emptyset, \varepsilon\}$ tel que:

- tout symbole de $\Sigma \cup \{\emptyset, \varepsilon\}$ est une expression régulière
- si r_1 et r_2 sont deux expressions régulières alors :
 - (r_1) est une expression régulière
 - $r_1 r_2$ est une expression régulière
 - $r_1 \cup r_2$ est une expression régulière
 - r_1^* est une expression régulière

EXPRESSIONS RÉGULIÈRES

Définition

L'interprétation d'une expression est définie par les règles suivantes :

- ε dénote le langage $\{\varepsilon\}$ et $\emptyset$ dénote le langage vide
- $\forall x \in \Sigma, x$ dénote le langage $\{x\}$
- $(r_1 \cup r_2)$ dénote l'union des langages dénotés par r_1 et par r_2
- $(r_1 r_2)$ dénote la concaténation des langages dénotés par r_1 et par r_2
- (r^*) dénote l'étoile du langage dénoté par r

EXPRESSIONS RÉGULIÈRES

Définition

- Ordre de priorité : l'étoile (*), puis la concaténation, puis l'union.
- Les opérateurs binaires sont associatifs à gauche.

Exemple :

$xy^* \cup y^*$ s'interprète comme $((x(y^*)) \cup (y^*))$

EXPRESSIONS RÉGULIÈRES

Quelques équivalences élémentaires

- $\emptyset e = e\emptyset = \emptyset$
- $\emptyset^* = \varepsilon$
- $e \cup \emptyset = e$
- $\varepsilon e = e\varepsilon = e$
- $\varepsilon^* = \varepsilon$
- $(e^*)^* = e^*$
- $e \cup e = e$
- $e \cup f = f \cup e$
- $e(f \cup g) = ef \cup eg$
- $(e \cup f)g = eg \cup fg$
- $(ef)^*e = e(fe)^*$
- $(e \cup f)^* = (e^*f)^*e^*$

EXPRESSIONS RÉGULIÈRES

Exercice:

Montrer que :

1. $bb^*(a^*b^* \cup \varepsilon)b = b(b^*a^* \cup \varepsilon)bb^*$
2. $a^*b(c \cup da^*b)^* = (a \cup bc^*d)^*bc^*$

EXPRESSIONS RÉGULIÈRES

Correction:

$$\begin{aligned} 1) \quad bb^*(a^*b^* \cup \varepsilon)b &= b(b^*a^*b^* \cup b^*.\varepsilon)b & e(f \cup g) &= ef \cup eg \\ &= b(b^*a^* \cup \varepsilon)b^*b & (e \cup f)g &= eg \cup fg \\ &= b(b^*a^* \cup \varepsilon)bb^* & (ef)^*e &= e(fe)^* \end{aligned}$$

$$\begin{aligned} 2) \quad a^*b(c \cup da^*b)^* & & (e \cup f)^* &= (e^*f)^*e^* \\ &= a^*b(c^*da^*b)^*c^* & (ef)^*e &= e(fe)^* \\ &= (a^*bc^*d)^*a^*bc^* & (e \cup f)^* &= (e^*f)^*e^* \\ &= (a \cup bc^*d)^*bc^* \end{aligned}$$

LANGAGES RÉGULIERS

Définition

Soit Σ un alphabet. Les langages réguliers sur Σ sont définis inductivement par :

- $\{\epsilon\}$ et $\emptyset$ sont des langages réguliers
- $\forall x \in \Sigma, \{x\}$ est un langage régulier
- si L_1 et L_2 sont des langages réguliers, alors $L_1 \cup L_2$, $L_1 L_2$, et L_1^* sont également des langages réguliers

Tous les langages finis sont réguliers.

LANGAGES RÉGULIERS

Théorème

Un langage L est dit régulier si et seulement s'il existe une expression régulière qui le génère.

⇒ pour prouver qu'un langage est régulier, il suffit de trouver une expression régulière qui le dénote.

LANGAGES RÉGULIERS

Exemple

Soit l'alphabet $\Sigma = \{a, b\}$

$L = \{\omega \in \Sigma^*, \omega \text{ ne contient pas 3b consécutifs}\}$

$R = (a \cup ba \cup bba)^* (\varepsilon \cup b \cup bb)$

LANGAGES RÉGULIERS

- Chaque expression dénote un unique langage, mais à un langage donné peuvent correspondre plusieurs expressions différentes.

Définition

Deux expressions régulières α et β sont équivalentes si elles dénotent le même langage ($L(\alpha) = L(\beta)$).

LANGAGES RÉGULIERS

Exemple

Le langage de tous les mots qui ont au moins 2a peut-être décrit par l'expression

$$(a \cup b)^* a (a \cup b)^* a (a \cup b)^*$$

Ou bien par l'expression

$$b^* a b^* a (a \cup b)^*$$